

Project #2

DB Mining & Document Search Engine & Classification

과제목적 : 이번 프로젝트는 연관 분석, 텍스트 데이터를 바탕으로 한 검색 엔진 모듈 및 분류 모델 구현을 목적으로 한다.

프로젝트는 크게 세 부분으로 나뉜다.

※ 모든 코드 파일의 TEAM = 0 을 반드시 자신의 팀 번호로 수정하라. 미수정 시 제출물 식별이 불가하여 감점.

PART I. 연관 분석

PART II. 문서 검색 엔진

PART III. 문서 분류

PART I. 연관분석

PART I 연관분석에서는 Q&A 사이트의 **tag** 들 간의 연관 분석을 목표로 한다. R1-1에서는 연관분석을 위한 horizontal table 의 결과를 반환하는 것을 목표로 하며, R1-2에서는 python 의 mlxtend 라이브러리를 사용하여 연관분석을 수행하고 결과를 출력하는 것을 목표로 한다.

(R1-1) (10%) 결과물: DMA_project2_team##_part1_horizontal.pkl

연관분석을 위해 pandas 로 DMA_project_UBR.csv 를 Load 하라. 이 파일은 question 과 tag 두 개의 컬럼으로 구성되어 있다. question id 를 index 로 가져야 하며, tag 이름들을 column 명으로 가지는 DataFrame 을 만들어라. 저장된 DataFrame 의 각 question 은 연관분석의 transaction 역할을, 각 tag 은 연관분석의 item 역할을 하게 된다. Pandas 라이브러리를 사용하여 해당 horizontal table 을 생성하고, 이를 DMA_project2_team##_part1_horizontal.pkl 에 저장한다.

(R1-2) (20%) 결과물: DMA_project2_team##_part1_association.pkl + 보고서

R1-1 에서 만든 DataFrame 을 사용해서 다음의 조건을 만족하는 frequent itemset 을 만들고 연관분석을 수행하라.

- Frequent itemset 의 최소 support: 0.005
- 연관분석 metric: lift, min_threshold: 2.0

- 결과 파일명: DMA_project2_team##_part1_association.pkl

또한, lift 임계값을 변경해가며 (예: 1.0, 1.5, 2.0, 3.0, 5.0, 10.0 등) 추출되는 연관 규칙의 변화를 분석하고, 다음 내용을 포함하는 **정성적·정량적 분석**을 보고서에 작성하라.

- lift 임계값에 따른 규칙 수의 변화

- 양의 연관 ($\text{lift} > 1$)과 음의 연관 ($\text{lift} < 1$) 규칙 각각의 해석

- 추출된 연관 규칙이 해당 Q&A 사이트의 특성과 부합하는지에 대한 분석

(예: 어떤 태그들이 함께 자주 등장하는지, 반대로 함께 등장하지 않는 태그들은 무엇이며 그 이유는 무엇인지)

PART II. 문서 검색 엔진

PART II에서는 주어진 질의어와 관련이 높은 순서대로 문서들을 나열하는 검색 엔진 모듈을 python 의 whoosh 라이브러리를 사용하여 구현하여야 한다.

- 사용 데이터: 통계/ML 학술 논문 데이터셋

- document.txt: 2,772 개 문서 파일
- query.txt: 80 개 질의어 파일
- relevance.txt: 각 질의어의 실제 연관 문서가 명시된 정답 파일

- 작성 모듈

- [선택] make_index.py: 문서의 ID 와 contents 를 index 에 저장하는 함수. 기본으로 주어진 index 를 사용하지 않을 시에 해당 모듈 작성
- QueryResult.py: 텍스트 형태의 질의어를 입력 받아 whoosh 질의어 객체로 변환 후 검색 결과 반환
- CustomScoring.py: 문서들을 질의어와 관련 높은 순서대로 나열할 때 사용하는 문서 채점 함수. 사용할 수 있다.

기본 정보로는

- ✓ 문서 내 단어 빈도(TF)
- ✓ 역문서 빈도(IDF)
- ✓ 전체 데이터셋 내 단어 빈도
- ✓ 문서 개수
- ✓ 문서 길이 (단어 개수)

✓ 전체 데이터셋 내 단어 개수

✓ 문서 당 평균 단어 개수

등이 있으며, 제공되는 정보 이외의 정보를 추출 가능하다면 추가적으로 사용할 수 있다

● 평가 방법

- 80 개의 질의어에 대한 검색 성능 평가
- 평가 지표로는 BPREF 사용 [evaluate.py 에서 자동으로 계산]

$$\text{Bpref} = \frac{1}{R} \sum_{r=1}^R 1 - \frac{|n \text{ ranked higher than } r|}{R}$$

- 성능 평가 점수 (30 점): 평균 BPREF * 30 점
- 성능 개선 보고서 (5 점): CustomScoring 및 QueryResult 에서 적용한 성능 개선 방법에 대한 근거와 정당화를 보고서에 서술하라. 어떤 방법을 왜 선택했는지, 기본 BM25F 대비 어떤 차이가 있는지 등을 포함해야 한다.

● 주의 사항

- CustomScoring.py 와 QueryResult.py 는 **범용적인 검색 엔진 모듈**로 구현하여야 한다. 즉, 어떤 질의어가 입력되더라도 동일한 로직으로 동작해야 하며, 특정 질의어나 특정 문서에 대한 예외 처리를 포함해서는 안 된다.

- 코드 내에서 relevance.txt 를 직접 또는 간접적으로 참조하는 행위를 절대 금지한다.

relevance.txt 는 평가 전용 파일이며, 검색 엔진 모듈(CustomScoring.py, QueryResult.py)에서 정답 정보를 활용하여 점수를 조작하는 것은 부정행위에 해당한다.

다음은 포함하되 이에 국한되지 않는다:

- ✓ relevance.txt 를 읽어 특정 문서에 가산점 부여
- ✓ relevance.txt 의 정답 문서를 분석하여 쿼리별 키워드 추출 후 활용
- ✓ 정답 문서 ID 를 하드코딩하여 검색 결과에 삽입

- 적발 시 **PART II 점수 전체 0 점 처리한다**

- 문서(document.txt) 분석은 허용한다. 문서의 통계적 특성(평균 길이, 용어 분포 등)을 파악하여 scoring function 을 설계하는 것은 정당한 검색 엔진 개선에 해당한다.

PART III. 문서 분류

PART III에서는 4 가지 카테고리의 학술 논문을 분류하는 모델을 python 의 sklearn 라이브러리를 사용하여 구현한다.

- JMLR, AnnStat, JASA, Biometrika 총 4 개의 카테고리 (학술 저널)
- 각 카테고리마다 250 개의 논문 데이터 제공 (200 개 train + 50 개 test)
- text 폴더 내부에 train/test 폴더 구분, 각 폴더 내에 4 개의 카테고리를 이름으로 하는 폴더 내에 텍스트 파일로 존재
- 주어진 데이터 외에 추가로 크롤링 등의 방법을 이용한 데이터 추가, 파일 수정, 제공된 데이터셋 일부만 사용은 허용하지 않는다
- 각 모델에 대해 학습시킨 모델을 pickle 파일로 저장하여 코드와 함께 제출한다

● 평가 방법

- 제공된 test 데이터 200 개에 대한 정확도(accuracy)로 평가
- clasification.py 실행 시 출력되는 accuracy 기준
- 3-1. Naïve Bayes Classifier
 - ✓ 점수 10 점: $\text{accuracy} * 10$
- 3-2. SVM
 - ✓ 점수 10 점: $\text{accuracy} * 10$

● 채점 기준

- **PART I (30%):** Horizontal (10%), Association + 분석 보고서 (20%)
- **PART II(35%):** 성능 평가 (30%) + 성능 개선 보고서 (5%)
- **PART III(20%):** NB 정확도 (10%) + SVM 정확도 (10%)
- 보고서 품질(10%), 발표(5%)

● 강의계획서에 기재된 바와 같이 프로젝트의 성적 반영 비중은 두 번의 프로젝트를 합쳐 30%이다.

결과물들을 'DMA_project2_team##.zip'파일로 압축하여 발표일 전날인 **6월 9일** 23:59 까지 ETL 에 업로드해야 한다. ETL 상에 문제가 생겼을 경우 **kimhun0505@snu.ac.kr** 로 오류 증명 파일과 함께 해당 일시까지 보내야 한다. 이 외 문제가 발생할 경우 사전 공지사항 및 제출해야 할 결과물과 파일명, 파일 확장자는 다음과 같다.

● 보고서 (20 페이지 이내)

- 파일명: DMA_project2_team##_보고서.pdf

● 발표 자료 및 발표

- 발표 자료 파일명: DMA_project2_team##_발표자료.pdf

● Python 프로그램 코드 및 결과물

- 사용 라이브러리는 pandas, numpy, sklearn 및

(PART I) collections, mlxtend

(PART II, III) nltk, whoosh, pickle 을 기반으로 한다.

필요하다면 다른 라이브러리를 사용할 수 있으나 이에 대해

kimhun0505@snu.ac.kr 로 사전에 메일을 보내야 한다.

- 문서 검색 엔진 구현에서 사용하려는 방법이 허용되는지 **매매할 경우 이메일 문의**

- csv 파일은 column 들 사이에 분리 기호는 콤마(,)여야 하며 row 들 사이에는 줄 넘김(\n)으로 구분되어야 한다.

- Pandas 의 DataFrame 을 pkl 으로 저장할 때는 to_pickle 함수를 이용하여 저장한다.

- AA 폴더 (PART I)

✓ part1.py

✓ DMA_project2_team##_part1_horizontal.pkl

✓ DMA_project2_team##_part1_association.pkl

- SE 폴더 (PART II)

✓ index 폴더: 주어진 index 혹은 신규 생성한 index

✓ make_index.py: 주어진 index 를 사용하지 않았을 경우 첨부

✓ CustomScoring.py

✓ QueryResult.py

- CL 폴더 (PART III)

✓ clasification.py

✓ DMA_project2_team##_nb.pkl: Naïve Bayes Classifier 이용한 모델

✓ DMA_project2_team##_svm.pkl: SVM 이용한 모델

- PART II, III 의 경우 추가 데이터 및 데이터 파일 가공은 허용하지 않았기에 첨부할 필요 없습니다.

- 각 모델의 결과를 제출 코드만을 실행하여 재현할 수 있어야 한다.